

《基于 MindSpore 的 PCA 降维 实验》



华为技术有限公司

版权所有 © 华为技术有限公司 2024 保留一切权利。

非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部，并不得以任何形式传播。

商标声明



和其他华为商标均为华为技术有限公司的商标。

本文档提及的其他所有商标或注册商标，由各自的所有人拥有。

注意

您购买的产品、服务或特性等应受华为公司商业合同和条款的约束，本文档中描述的全部或部分产品、服务或特性可能不在您的购买或使用范围之内。除非合同另有约定，华为公司对本文档内容不做任何明示或暗示的声明或保证。

由于产品版本升级或其他原因，本文档内容会不定期进行更新。除非另有约定，本文档仅作为使用指导，本文档中的所有陈述、信息和建议不构成任何明示或暗示的担保。

华为技术有限公司	
地址：	深圳市龙岗区坂田华为总部办公楼 邮编：518129
网址：	http://e.huawei.com



目录

1 PCA 降维实验	2
1.1 实验介绍.....	2
1.1.1 简介	2
1.1.2 实验目的.....	3
1.1.3 预备知识.....	3
1.2 实验环境搭建.....	3
1.3 实验过程.....	3
1.3.1 数据准备	3
1.3.2 导入 MindSpore 模块和辅助模块.....	4
1.3.3 加载并处理数据	4
1.3.4 构建 PCA 降维网络	5
1.3.5 PCA 降维操作	6
1.4 实验小结	6

1 PCA 降维实验

1.1 实验介绍

1.1.1 简介

降维是一种对高维度特征数据预处理方法。降维是将高维度的数据保留下最重要的一些特征，去除噪声和不重要的特征，从而实现提升数据处理速度的目的。在实际的生产和应用中，降维在一定的信息损失范围内，可以为我们节省大量的时间和成本。降维也成为应用非常广泛的数据预处理方法。本实验主要介绍使用 MindSpore 在多维度数据集上进行 PCA 降维实验。

降维具有如下一些优点：

- 使得数据集更易使用。
- 降低算法的计算开销。
- 去除噪声。
- 使得结果容易理解。

降维的算法有很多，比如奇异值分解(SVD)、主成分分析(PCA)、因子分析(FA)、独立成分分析(ICA)。本实验使用 PCA 实现降维。PCA (Principal Component Analysis) 是一种使用最广泛的数据降维算法，常用于高维数据的降维，可用于提取数据的主要特征分量。其主要思想是将 n 维特征映射到 k 维上，这 k 维是全新的正交特征也被称为主成分，是在原有 n 维特征的基础上重新构造出来的 k 维特征。

PCA 的算法步骤：

设有 m 条 n 维数据。

将原始数据按列组成 n 行 m 列矩阵 X ；

将 X 的每一行进行零均值化，即减去这一行的均值；

求出协方差矩阵 $C = \frac{1}{m} XX^T$ ；

求出协方差矩阵的特征值及对应的特征向量；

将特征向量按对应特征值大小从上到下按行排列成矩阵，取前 k 行组成矩阵 P ；

$Y = PX$ 即为降维到 k 维后的数据。

1.1.2 实验目的

- 了解降维算法和 PCA 的基本概念；
- 了解如何使用 MindSpore 进行降维实验；

1.1.3 预备知识

- 熟练使用 Python。
- 具备一定的机器学习理论知识，如 PCA、监督学习、无监督学习，训练策略等。
- 了解并熟悉 MindSpore AI 计算框架，MindSpore 官网：<https://www.mindspore.cn/>

1.2 实验环境搭建

本实验在华为云 ModelArts 上进行，开发环境搭建可参考如下手册：ModelArts 云环境环境搭建指南。



华为云 ModelArts
环境搭建手册.docx

1.3 实验过程

1.3.1 数据准备

Iris 数据集是模式识别最著名的数据集之一。数据集包含 3 类，每类 50 个实例，其中每个类都涉及一种鸢尾植物。 本实验使用 iris 数据集，做一个降维数据集。

下载 Iris.data 数据文件，下载链接：<https://ascend-professional-construction-dataset.obs.cn-north-4.myhuaweicloud.com/MachineLearning/iris.data>

下载的数据中，每个样本含有 4 个数值属性和一个类别属性：

4 个数值属性：sepal length；sepal width；petal length；petal width。

一个类别属性，属性值如下：


- Iris Setosa
- Iris Versicolour
- Iris Virginica

概括统计：

Attribute	Min	Max	Mean	SD	Class Correlation
-----------	-----	-----	------	----	-------------------

sepal length:	4.3	7.9	5.84	0.83	0.7826
sepal width:	2.0	4.4	3.05	0.43	-0.4194
petal length:	1.0	6.9	3.76	1.76	0.9490 (high!)
petal width:	0.1	2.5	1.20	0.76	0.9565 (high!)

实验开始前，在云环境中，请通过下图所示的上传按钮，将下载的数据上传至 ModelArts 实验平台。



1.3.2 导入 MindSpore 模块和辅助模块

```
import os
import csv
import numpy as np
import seaborn as sns
import mindspore as ms
import matplotlib.pyplot as plt

from mindspore import nn, context
from mindspore.ops import operations as ops
context.set_context(mode=context.PYNATIVE_MODE, device_target="Ascend")
```

1.3.3 加载并处理数据

读取 Iris 数据集 iris.data；并检查部分数据。

```
with open('iris.data') as csv_file:
    data = list(csv.reader(csv_file, delimiter=';'))
print(data[0:5], data[50:55], data[100:105]); # print some samples
```

数据集有 3 类样本共 150 条，将样本的 4 个属性作为自变量 X ，将样本的 3 个类别映射为 $\{0, 1, 2\}$ ，作为因变量 Y 。

```
label_map = {
    'Iris-setosa': 0,
    'Iris-versicolor': 1,
    'Iris-virginica': 2
}
X = np.array([[float(x) for x in s[:-1]] for s in data[:150]], np.float32)
Y = np.array([label_map[s[-1]] for s in data[:150]], np.int32)
```

1.3.4 构建 PCA 降维网络

利用 MindSpore 提供的 ReduceMean，Reshape，MatMul，TopK，GatherV2 等算子，通过矩阵运算的方式对输入样本数据进行操作，计算出降维到 k 维后的数据。

```
class PcaNet(nn.Cell):

    def __init__(self):
        super(PcaNet, self).__init__()
        self.reduce_mean = ops.ReduceMean(keep_dims=True)
        self.reshape = ops.Reshape()
        self.matmul_a = ops.MatMul(transpose_a=True)
        self.matmul_b = ops.MatMul(transpose_b=True)
        self.top_k = ops.TopK(sorted=True)
        self.gather = ops.Gather()

    def construct(self, x, dim=2):
        """
        x:输入矩阵
        dim:降维之后的维度数
        """
        m = X.shape[0]
        # 计算张量的各个维度上的元素的平均值
        mean = self.reduce_mean(x, axis=1)
        # 去中心化
        x_new = x - self.reshape(mean, (-1, 1))
        # 无偏差的协方差矩阵
        cov = self.matmul_a(x_new, x_new) / (m - 1)
        # 计算特征分解
        cov = cov.asnumpy()
        e, v = np.linalg.eigh(cov)
        # 将特征值从大到小排序，选出前 dim 个的 index
        e_index_sort = self.top_k(ms.Tensor(e), dim)[1]
        # 提取前排序后 dim 个特征向量
        v_new = self.gather(ms.Tensor(v), e_index_sort, 0)
```

```
# 降维操作
pca = self.matmul_b(x_new, v_new)
return pca
```


1.3.5 PCA 降维操作

将样本数据转换为 Tensor 格式后进行 PCA 降维操作；将 4 维的 iris 数据通过 PCA 转化为 2 维数据，再通过 matplotlib 模块进行可视化展示出来。

```
net = PcaNet()
pca_data = ms.Tensor(np.reshape(X,(X.shape[0],-1)),ms.float32)
pca_data = net(pca_data,dim=2)

# 可视化数据降维后效果图
color_mapping = {0: sns.xkcd_rgb['bright purple'],1: sns.xkcd_rgb['pale red'], 2: sns.xkcd_rgb['green']}
colors = list(map(lambda x: color_mapping[x], Y))
plt.scatter(pca_data[:, 0].asnumpy(), pca_data[:, 1].asnumpy(), c=colors)
plt.show()
```

实验结果：



1.4 实验小结

本实验利用降维的思想，通过 MindSpore 实现了 PCA 降维。在 Iris 数据集上进行降维后，把多属性的数据转化为少数几个综合属性。PCA 作为一个非监督学习的降维方法，它只需要特征值分解，就可以对数据进行压缩和去噪。